

Big Data

Pertemuan Satu

To Do Reminder

- Presensi Mahasiswa
- Pengambilan Dokumentasi Kelas
- Isi SIPA

Kontrak Perkuliahan

- **Minimal** hadir 75%.
- Mahasiswa yang absen **3 kali** berturut tidak dibenarkan dapat perkuliahan selanjutnya.
- Handphone **di-off-kan** selama perkuliahan.
- Keterlambatan.
 - Boleh masuk.
 - Jika sudah selesai presensi, secara administrasi **absen**, tetapi tetap dapat mengikuti perkuliahan.
- Izin atau sakit: wajib konfirmasi dengan **bukti** yang relevan.

Materi

Minggu	Materi	Ringkasan Materi
1	Pengantar Big Data & 5V, use case Informatika	5V dan karakteristik data
2	Arsitektur data modern: data lake/warehouse.	Data lake vs warehouse; batch vs streaming; alur pipeline data modern.
3	Hadoop ecosystem overview: HDFS, YARN, MapReduce	Gambaran ekosistem; peran storage vs compute
4	Managing Cluster (HDFS)	HDFS block/replication; permission; operasi dasar; read/write
5	Managing Cluster (YARN)	Resource manager & node manager; antrian; monitoring; membaca log dasar
6	MapReduce workflow batch	Map, shuffle/sort, reduce; contoh wordcount; kapan MapReduce digunakan
7	Programming Hadoop with Spark	Spark architecture; DataFrame; transform/action; partition & cache

Materi


Menjelaskan karakteristik Big Data dan mengidentifikasi use case pada Big Data.	Karakteristik Big Data & use cases
Membedakan arsitektur batch vs stream dan menjelaskan kapan dipakai.	Arsitektur Big Data (batch vs stream)
Menjelaskan konsep sistem file terdistribusi (partisi, replikasi, locality).	Sistem file terdistribusi
Menguraikan konsep MapReduce dan alur map-shuffle-reduce.	Pemrosesan batch (MapReduce concept)
Menjelaskan pemrosesan in-memory dan konsep DAG serta keunggulannya.	Pemrosesan in-memory & DAG
Menjelaskan konsep stream processing dan isu latency/window (konseptual).	Stream processing
Menjelaskan ingest & integrasi data skala besar (ETL/ELT, multi-source).	Ingesti & integrasi data skala besar

Pengantar Perkuliahan

- Mahasiswa memahami mengapa sebuah data disebut “*big*”
- Mengenal **5V** :
 - Volume,
 - Velocity
 - Variety
 - Veracity
 - Value

Learning Outcomes & Agenda

- Menjelaskan **5V Big Data** (Volume, Velocity, Variety, Veracity, Value).
- Memberi contoh sumber data: log, IoT, transaksi, multimedia.



5V

Big Data sering dijelaskan dengan 5V: karakteristik yang membuat pengelolaan data butuh pendekatan berbeda.

v

Volume

Ukuran data sangat besar :
storage & komputasi harus
skalabel.

v

Velocity

Data mengalir cepat :
ingestion & pemrosesan real-
time/near real-time.

v

Variety

Bentuk data beragam :
struktur berbeda (teks,
gambar, log, sensor, dll.).

v

Veracity

Kualitas/ketidakpastian data:
noise, missing value, bias,
outlier.

v

Value

Nilai bisnis/ilmiah: insight,
keputusan, otomasi, efisiensi.

Volume



Volume — ukuran data sangat besar sehingga butuh **storage & komputasi** yang skalabel.

Pertanyaan kunci: “**data akan tumbuh secepat apa?**”

Sumber data

- Log web (jutaan baris/hari)
- Data sensor IoT (telemetry periodik)
- Riwayat transaksi (tumbuh terus)

Indikator yang sering dipakai

- GB → TB → PB
- Jumlah record/event per periode
- Ukuran file & partisi

Velocity



Velocity — Seberapa cepat **data** dibuat, didistribusikan dan diproses.

Pertanyaan kunci: “**butuh real-time atau cukup batch?**”

Sumber Data

- Klik pengguna real-time
- Sensor mengirim data tiap detik/menit
- Transaksi pembayaran *online*

Indikator yang sering dipakai

- Event per detik (EPS)
- Latency end-to-end
- Jitter
- Throughput ingestion

Variety

Variety — **banyak** format: terstruktur, semi-terstruktur, dan tidak terstruktur.

Pertanyaan kunci: “**format data apa saja yang harus ditangani?**”

Contoh sumber data

- Tabel (CSV/SQL)
- JSON log & event
- Gambar/video/audio, teks bebas

Indikator yang sering dipakai

- Jumlah format/sumber
- Skema berubah (schema drift)
- Kebutuhan parsing & normalisasi

Veracity

Veracity — tingkat kepercayaan/kualitas data: noise, bias, missing, outlier.

Pertanyaan kunci: **“seberapa bersih & bisa dipercaya data kita?”**

Sumber data

- Log berisi bot/spam
- Sensor error/kalibrasi melenceng
- Transaksi duplikat/rollback

Indikator yang sering dipakai

- Missing rate
- Outlier rate
- Duplikasi
- Validasi aturan bisnis

Value



Value — nilai yang dihasilkan: *insight*, keputusan lebih baik, otomasi, efisiensi.

Pertanyaan kunci: “**indikator suksesnya apa?**”

Sumber data

- Deteksi fraud
- Prediksi demand
- Monitoring kualitas layanan (SLA)

Indikator yang sering dipakai

- Metrik bisnis (revenue, cost, churn)
- Metrik model (AUC, F1)
- Metrik operasi (latency, error rate)